I. About this homework:

這份報告共分為五部分。第一部分,我們首先將 15000 筆的資料分為 training, validation, testing data;接下來第二跟三部分,分別使用 Maximum Likelihood Estimation (MLR)跟 Bayesian Linear Regression (BLR)進行 prediction;第四部分則是比較這兩種回歸模型(MLR, BLR)的差異;最後,第五部分,我們使用 sklearn 的內建模型 Gradient Boosting Regressor來跑本次作業,並做討論。

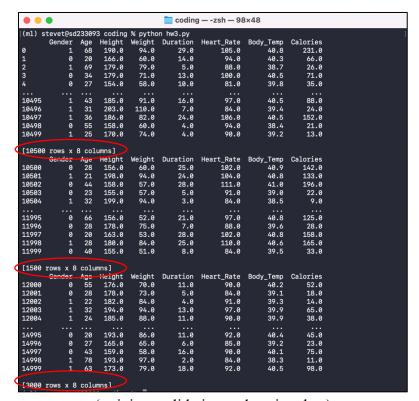
II. Data splitting:

1. Detailed implementation:

我們先將 exercise.csv 跟 calroies.csv 合併成 merged.csv,因為 User_ID 不重要,所以我們直接將此 column 刪除;另外,第一個 feature, Gender 的部分,為求方便,我們將 Male 更改為"1", Female 更改為"0"。最後以 training data, validation data, testing data 等於 70:10:20 的比例,將 15000 筆 data,分別分割成 10500, 1500, 3000 筆。

1	Gender	Age	Height	Weight	Duration	Heart_Rate	Body_Temp	Calories
2	1	68	190	94	29	105	40.8	231
3	0	20	166	60	14	94	40.3	66
4	1	69	179	79	5	88	38.7	26
5	0	34	179	71	13	100	40.5	71
6	0	27	154	58	10	81	39.8	35

(merged.csv)



(training, validation and testing data)

2. Code:

這部分 code 在 python 的 main()的第一部分,基本上只要執行一遍即可。

```
'''01: Data preprocessing (Only do once)'''
calories_df = pd.read_csv('calories.csv')
exercise_df = pd.read_csv('exercise.csv')
exercise_df = exercise_df.drop(calories_df.columns[0], axis=1)
calories_df = calories_df.drop(calories_df.columns[0], axis=1)
merged_df = pd.concat([exercise_df, calories_df], axis=1)
merged_df['Gender'] = merged_df['Gender'].replace({'male': 1, 'female': 0})
merged_df.to_csv('merged_data.csv', index=False)
total_samples = len(merged_df)
train size = 10500
val_size = 1500
test_size = 3000
train_data = merged_df[:train_size]
val_data = merged_df[train_size:train_size + val_size]
test_data = merged_df[train_size + val_size:]
train_data.to_csv('train_data.csv', index=False)
val_data.to_csv('val_data.csv', index=False)
test_data.to_csv('test_data.csv', index=False)
```

(第一部分 code)

III. Maximum Likelihood Estimation (MLR):

1. Detailed implementation:

這部分細節主要參考課本 3.1.1 節,首先將 training data 的 features 跟 label 分開,將 features 寫成 feature vector (Φ)進行處理,接下來將 training data 的 label 帶入 t,即可 進行 model's weight 的計算,如課本 3.15 公式:

$$\mathbf{w}_{\mathrm{ML}} = \left(\mathbf{\Phi}^{\mathrm{T}}\mathbf{\Phi}\right)^{-1}\mathbf{\Phi}^{\mathrm{T}}\mathbf{t}$$

另外 prediction 的部分,需先將 testing data 的 features 分出來,之後直接乘上上面所計算的 weight 即可以得到 prediction。

2. Code:

Code 的部份原則上跟上述數學式一樣,但我在 training features 跟 testing features 都 先加入了一行數值為 1 的 column,當作 intercept term (或 bias term)這是在 linear regression 常見的做法,主要是在估計時可以更準確訓練出 intercept 值,這樣對於 features 跟目標變數的關係會更準確,也可以得到更好的預測值。另外,根據題目要求,MLR 是要針對 testing data 做測試,而下方 BLR 則是對 validation data 做測試,

```
def MLR(train_data, test_data_feature):
    train_data_feature = train_data[:, :7]
    train_data_label = train_data[:, 7]

train_data_feature = np.c_[np.ones(train_data_feature.shape[0]), train_data_feature]
    coefficients = np.linalg.inv(train_data_feature.T.dot(train_data_feature)).dot(train_data_feature.T).dot(train_data_label)

test_data_feature = np.c_[np.ones(test_data_feature.shape[0]), test_data_feature]

MLR_predictions = test_data_feature.dot(coefficients)

return MLR_predictions
```

3. Mean squared error (MSE) function:

```
def MSE(data, prediction):
    mse = np.mean((prediction - data) ** 2)
    return mse
```

4. The result:

IV. Bayesian Linear Regression

1. Detailed implementation:

參考課本 3.3 節,Bayesian 的 feature vector 用法跟上方 Maximum Likelihood 很像,如果參考課本的(3.50), (3.51),用 $S_0^{-1}=\alpha I$ 帶入來計算 weight,會發現最後 weight 跟上面 MLR 的 weight 只差加入一個 λI ,其中 $\lambda=\frac{\alpha}{\beta}$ 。

$$\mathbf{m}_{N} = \mathbf{S}_{N} \left(\mathbf{S}_{0}^{-1} \mathbf{m}_{0} + \beta \mathbf{\Phi}^{\mathrm{T}} \mathbf{t} \right)$$

$$\mathbf{S}_{N}^{-1} = \mathbf{S}_{0}^{-1} + \beta \mathbf{\Phi}^{\mathrm{T}} \mathbf{\Phi}.$$

Weight:

2. Code:

```
def BLR(train_data, test_data_feature):
    train_X = train_data[:, :-1]
    train_y = train_data[:, -1]

train_X = np.c_[np.ones(train_X.shape[0]), train_X]

X_transpose_X = train_X.T.dot(train_X)

X_transpose_y = train_X.T.dot(train_y)

posterior_precision = np.linalg.inv(X_transpose_X + np.eye(X_transpose_X.shape[0]))

posterior_mean = posterior_precision.dot(X_transpose_y)

test_X = np.c_[np.ones(test_data_feature.shape[0]), test_data_feature]

BLR_predictions = test_X.dot(posterior_mean)

return BLR_predictions
```

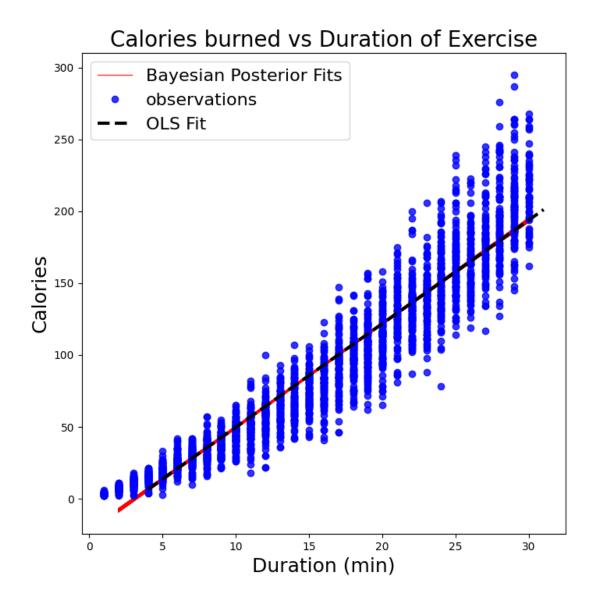
3. The result:

```
coding — -zsh — 98x22

[(ml) stevet@sd233093 coding % python hw3.py
MLR Predicted Calories:
[50.66155632 4.90557247 6.65496169 ... 78.90362555 26.52384564
181.4621983 ]
BLR Predicted Calories:
[141.82742953 140.49313035 184.83612018 ... 155.66857867 163.23154688
21.96736147]
MLR Mean Squared Error: 134.12367875356205
BLR Mean Squared Error: 132.45717148420502
(ml) stevet@sd233093 coding %
```

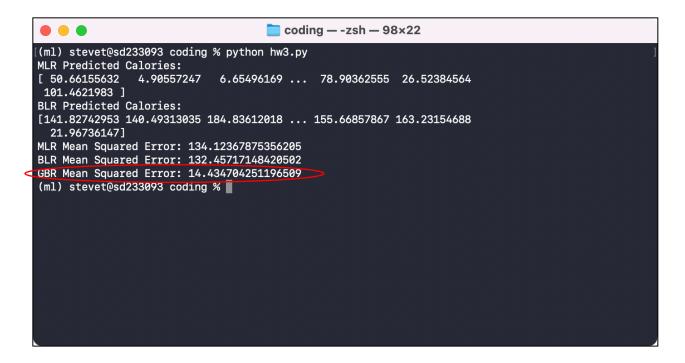
V. Comparison of BLR & MLR:

這部分需要分別畫出 MLR 跟 BLR 的 fit line,我參考[1]的做法,並按照助教提供的題目要求,針對兩個已經處理好的 regression models,使用單一 feature: "duration"跟 label: "calories" 畫出 Fit line。我自己的想法,我認為這兩種回歸的方法其實非常相似,因為兩者在 weight 的計算上只差了一項 λI ,而加入這項 regularization term (λI)主要是讓參數估計值較不會趨近於 0,且可以讓值更趨近 prior distribution,因此訓練出來的模型相較於 MLR 可以產生更準確的估計值,歸功於多了一項 regularization 的步驟。



VI. The other model:

我這裡直接選擇 sklearn 中的 GradientBoostingRegressor()並使用 training data 做 fit,並對 testing data 做預測。Gradient Boost是非常好用的方法,概念就是先用一個基本的 regression tree 當做 prediction (可能非常不準確),之後在幾次迭代中使用 Residual value,也就是 prediction 跟真實值的差異,來持續修正 model,當 Residual 降低, model 的預測值也會更好。如果要更進一步說明 Residual,其實他的值就是針對 loss function (using MSE) 做 Gradient descent 後的值,所以當降低 Residual,也代表模型預測更準確。我最後得到的 MSE,相較於 MLE,BLR 好非常多。



VII. Reference:

[1] https://www.kaggle.com/code/sathi557/bayesian-linear-regression-demo/notebook